University of Pittsburgh

Оптимизация курсов в эру больших данных и машинного обучения

Михаил Юдельсон

Старший научный сотрудник, ACT, Inc.
Приглашенный научный сотрудник, Университет Карнеги Меллон

Carnegie Mellon University

Оптимизация курсов в эру больших данных и машинного обучения

Михаил Юдельсон

Старший научный сотрудник, ACT, Inc.
Приглашенный научный сотрудник, Университет Карнеги Меллон

Коротко о себе

2004 Кандидат технических наук
Ивановский Государственный Энергетический Университет

2010 Докторская степень в Информатике
Питтсбургский Университет (рук. П.Л. Брусиловский)

2010-2013 Пост-док
Университет Карнеги Меллон (рук. К.Кёдингер, Дж. Гордон)

2013-2016 Научный сотрудник
Carnegie Learning, Inc.

2016-н.в. Приглашенный научный сотрудник
Университет Карнеги Меллон

2017-н.в. Старший научный сотрудник
ACT, ACTNext

Структура Доклада

- Построение курсов онлайн обучения
  - Архитектура систем адаптивного обучения
- Оптимизация курсов онлайн обучения
  - Моделирование знаний студентов
  - Моделирование знаний на основе больших данных
  - Использования моделей знаний для оптимизации курсов (пример МООК* по Java)

*МООК – Массовый Открытый Онлайн Курс

Архитектура

систем адаптивного обучения

Архитектура систем адаптивного обучения

- Архитектура это…
  - Важно
  - Емко по времени и ресурсам для создания и развития
  - То, что хочется постоянно переделать или сделать с нуля
- Компоненты архитектуры адаптивного обучения
  деление на компоненты обусловлено отличающимися наборами знаний и умений для создания компонентов и их сопровождения
  - Портал (система управление обучением)
  - Серверы доставки материала (содержание курсов)
  - Сервер моделей пользователей (пользовательская статистика)
  - Сервисы добавочного обслуживания (value-added service)
    - Оболочки адаптивного доступа
    - Плагины адаптивного доступа для портала

Портал (система управления обучением)

- Портал KnowledgeTree
  - Точка входа, аутентификация и авторизация
  - Данные о пользователях
  - Деление пользователей на курсовые группы (для сервера моделей пользователя и сервисов добавочного обслуживания)

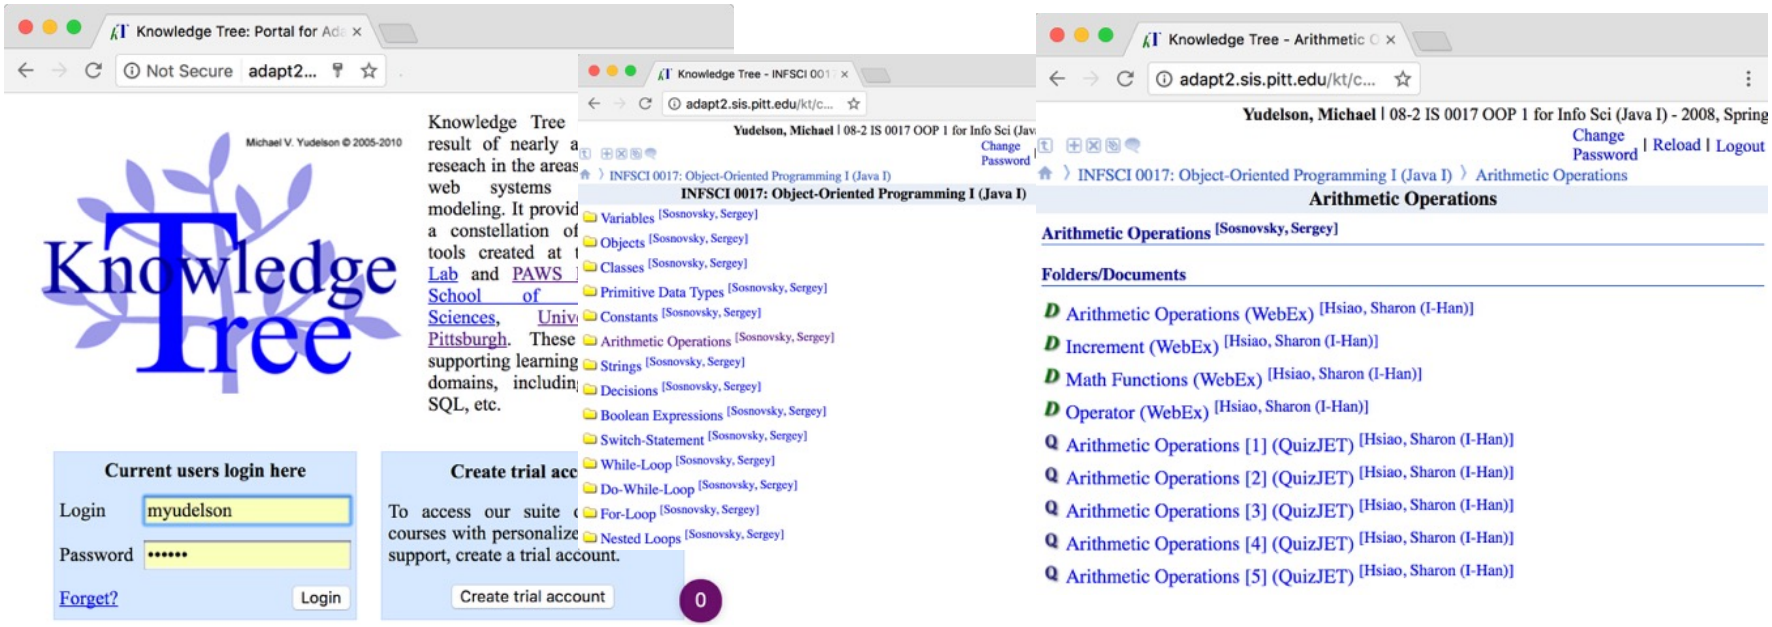

Сервер доставки материала (1)

- Элемент материала получает (и передает без изменений)
  - Код пользователя, код группы, код сессии (от портала)
- Элемент материала «знает о себе»
  - Само-описание в концептах (для программирования: цикл for, объявление переменной)
- Элемент материала передает серверу моделей пользователя
  - Код элемента, результат взаимодействия (просмотрено, решено правильно, решено неправильно)

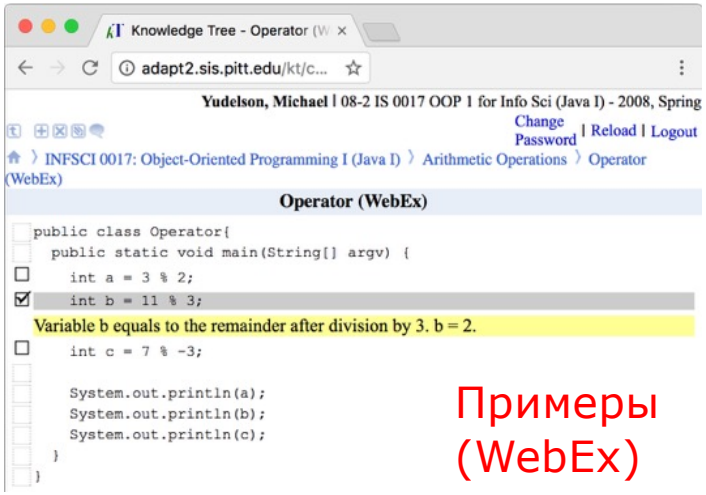

Примеры (WebEx)

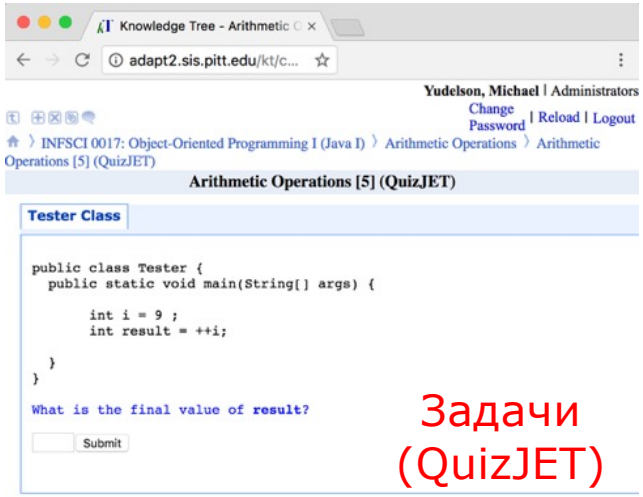

Задачи (QuizJET)

Сервер доставки материала (2)

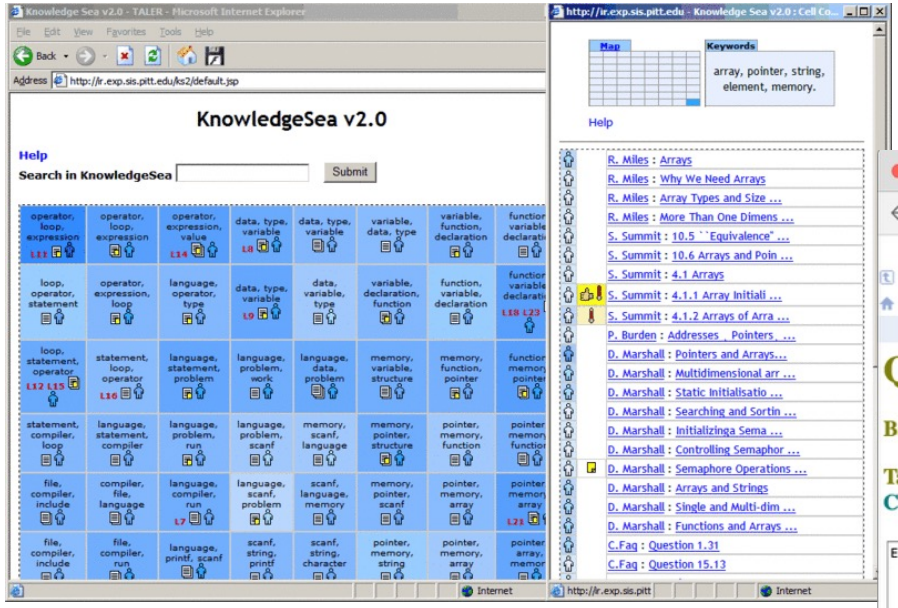

Руководства по Си (Knowledge Sea)

Задачи по SQL (SQLKnoT)

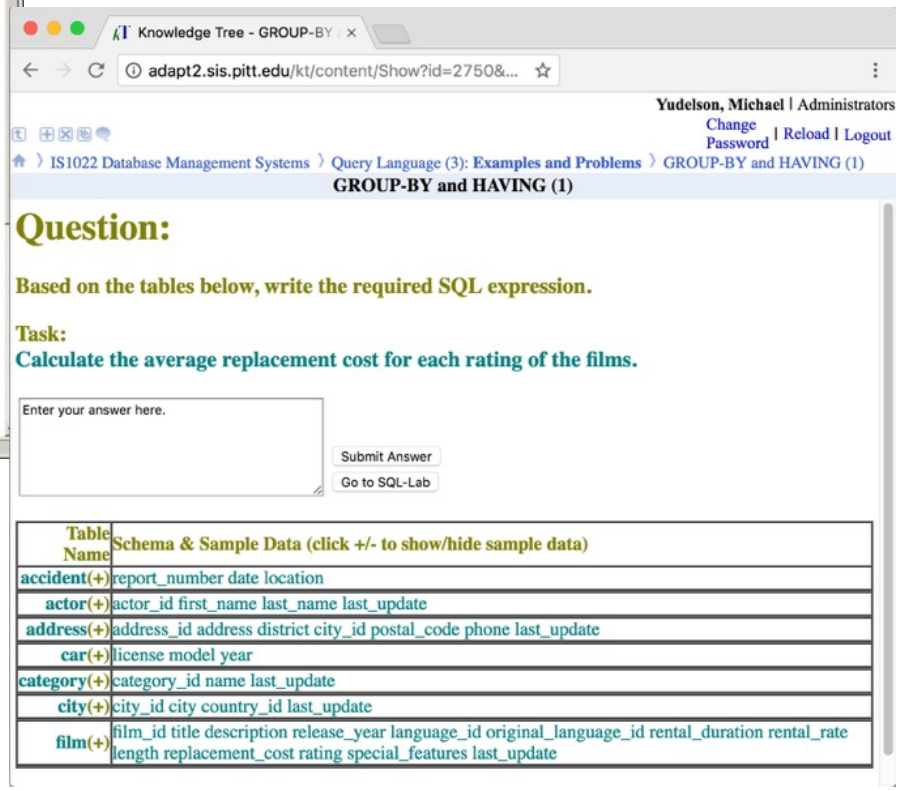

Сервер моделей пользователей (1)

- Центральный сервер моделей CUMULATE
- Сбор обработка, и вычисление статистики о пользователях
  - Время чтения материала (руководства и эл. книги)
  - Процент исследованных комментариев (примеры)
  - Количество событий доступа к элементу материала
  - Эмпирическая модель знаний концептов (нет штрафов за ошибки)

$$k_0 = 0$$

$$k_{n+1} = k_n + res \times (1 - k_n)^2 \times \begin{cases} k_n \le .5 & w'/2 \\ k_n > .5 & w' \end{cases}$$

$$w' = \sqrt[4]{\frac{w_{c,p}}{\sum_i w_{c_i p}\left({}_{succ}att_p + 1\right)}}$$

Сервер моделей пользователей (2)

- На прием
  - Отчеты о доступе к ресурсам (страница портала, элемент материала) и результате этого доступа (просмотрено/загружено/прочитано, решено правильно, решено неправильно)
- На передачу
  - Состояние индивидуальной или групповой модели пользователя (уровни знаний по концептам, процент исследования комментариев)

Сервисы добавочного обслуживания

- Вынесенные в виде адаптивных оболочек
- Встроенные в виде плагинов

А. навигация по примерам (NavEx)

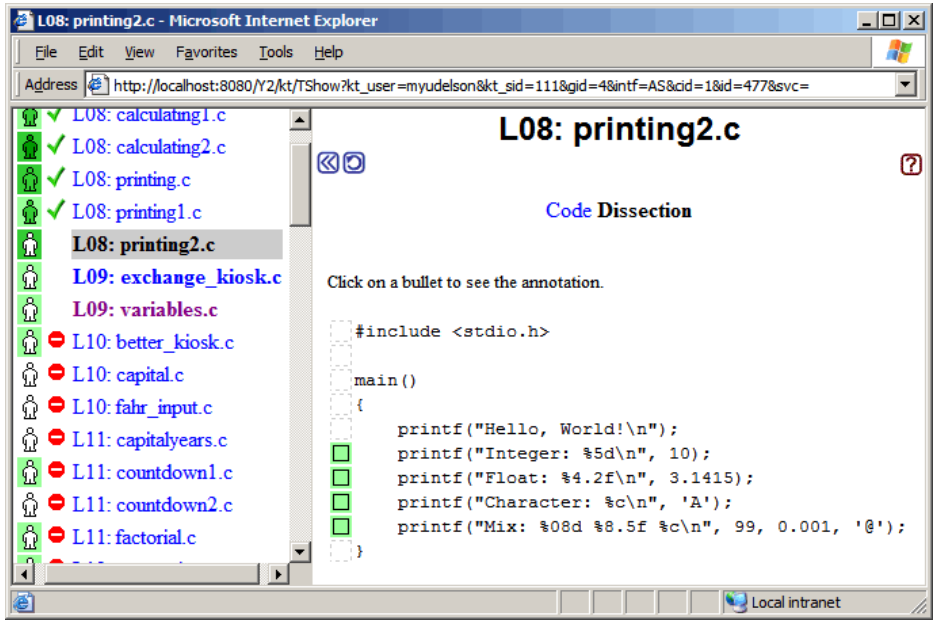

Плагин для адаптации (PERSEUS)

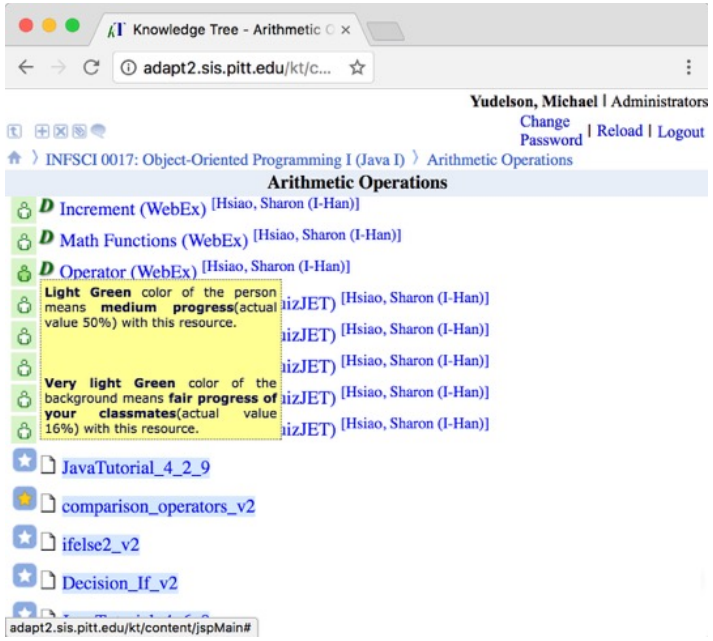

Движок Адаптации PERSEUS (1)

- Идея
  - Адаптация это сервис в пределах архитектуры
  - «Тонкий» клиентский портал не требующий радикальной перестройки
  - Замена программирования конфигурацией при развертывании адаптации
- Исполнение
  - Разделение на сервисы, конфигурации, источники данных и визуализации
  - Пакетный вызов сервисов

Движок Адаптации PERSEUS (2)

- Сервисы
  - Вычислительные методы (например средний уровень знаний по концепту для пары пользователь-элемент материала)
  - Тип адаптивной поддержки (напр. социальная навигация на основе уровня знаний концептов)
- Конфигурации
  - Объединяют внешние источники данных, статический XML, и сервис
- Источники данных (внешние)
  - Модель пользователя, структура страницы курса на портале, членство пользователя в курсовой группе
- Визуализации
  - Проекция вычисленных значений на набор графических средств отображения
- Вызов к PERSEUS
  - Сервис + Конфигурация + визуализация в контексте XML описания ресурсов требующих адаптации (чаще – страница портала)

Движок Адаптации PERSEUS (3)

2. Индивидуальный и групповой прогресс в виде комбинированной иконки

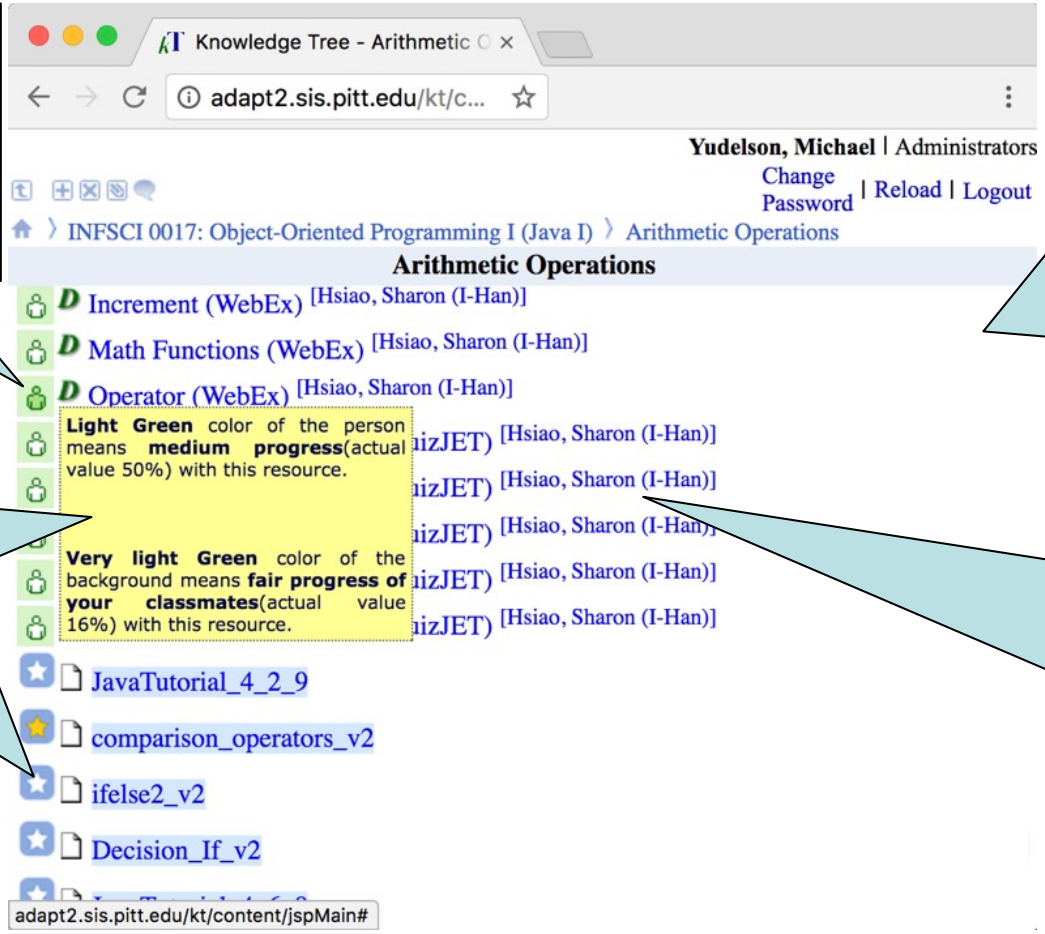

1. Портал посылает движку XML с URI всех ссылок, а получает XML с аннотацией и элементами JavaScript

3. Всплывающая подсказка объясняет суть визуализации

4. Пакетный вызов для добавление дополнительных примеров и JavaScript кода их оценки (звездочка)

5. В ссылки добавляется идентификатор вызова сервиса, позволяющий восстановить полную картину, которую видит пользователь.

Движок Адаптации PERSEUS (4)

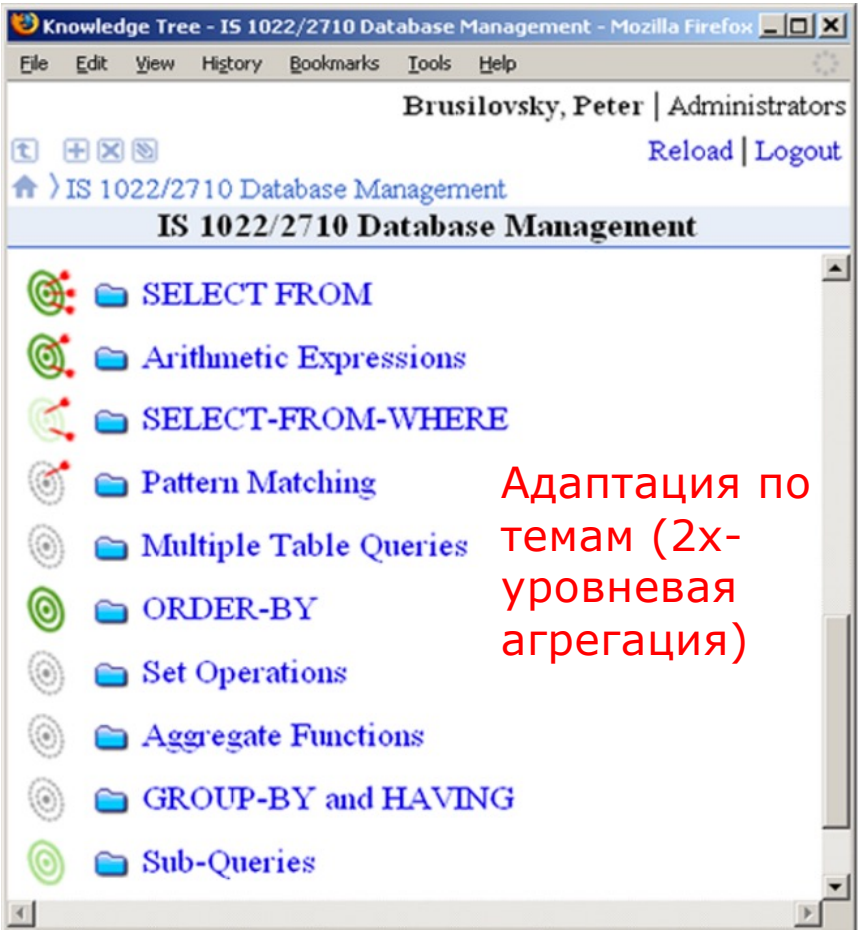

Адаптация по темам (2х-уровневая агрегация)

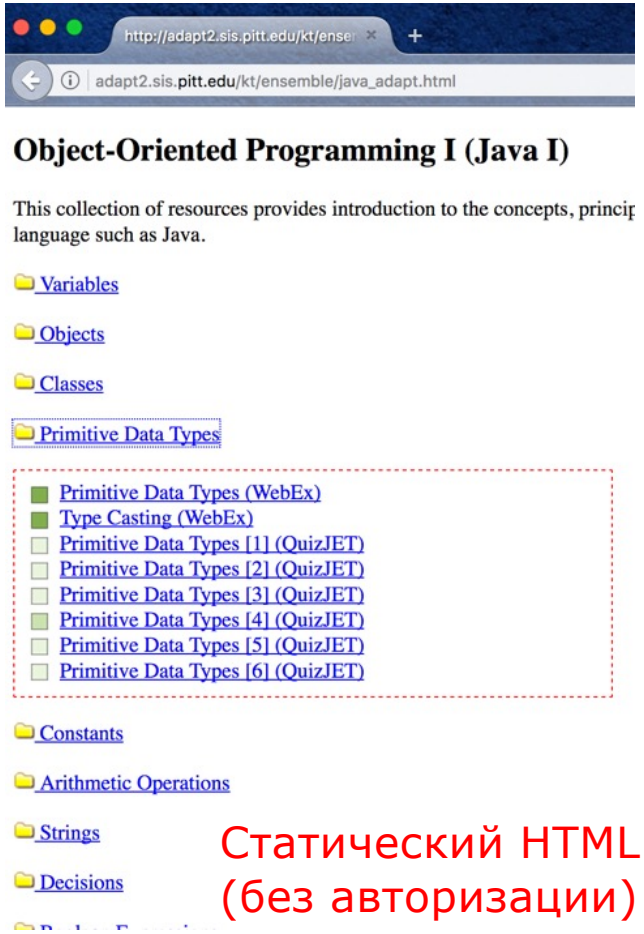

Статический HTML (без авторизации)

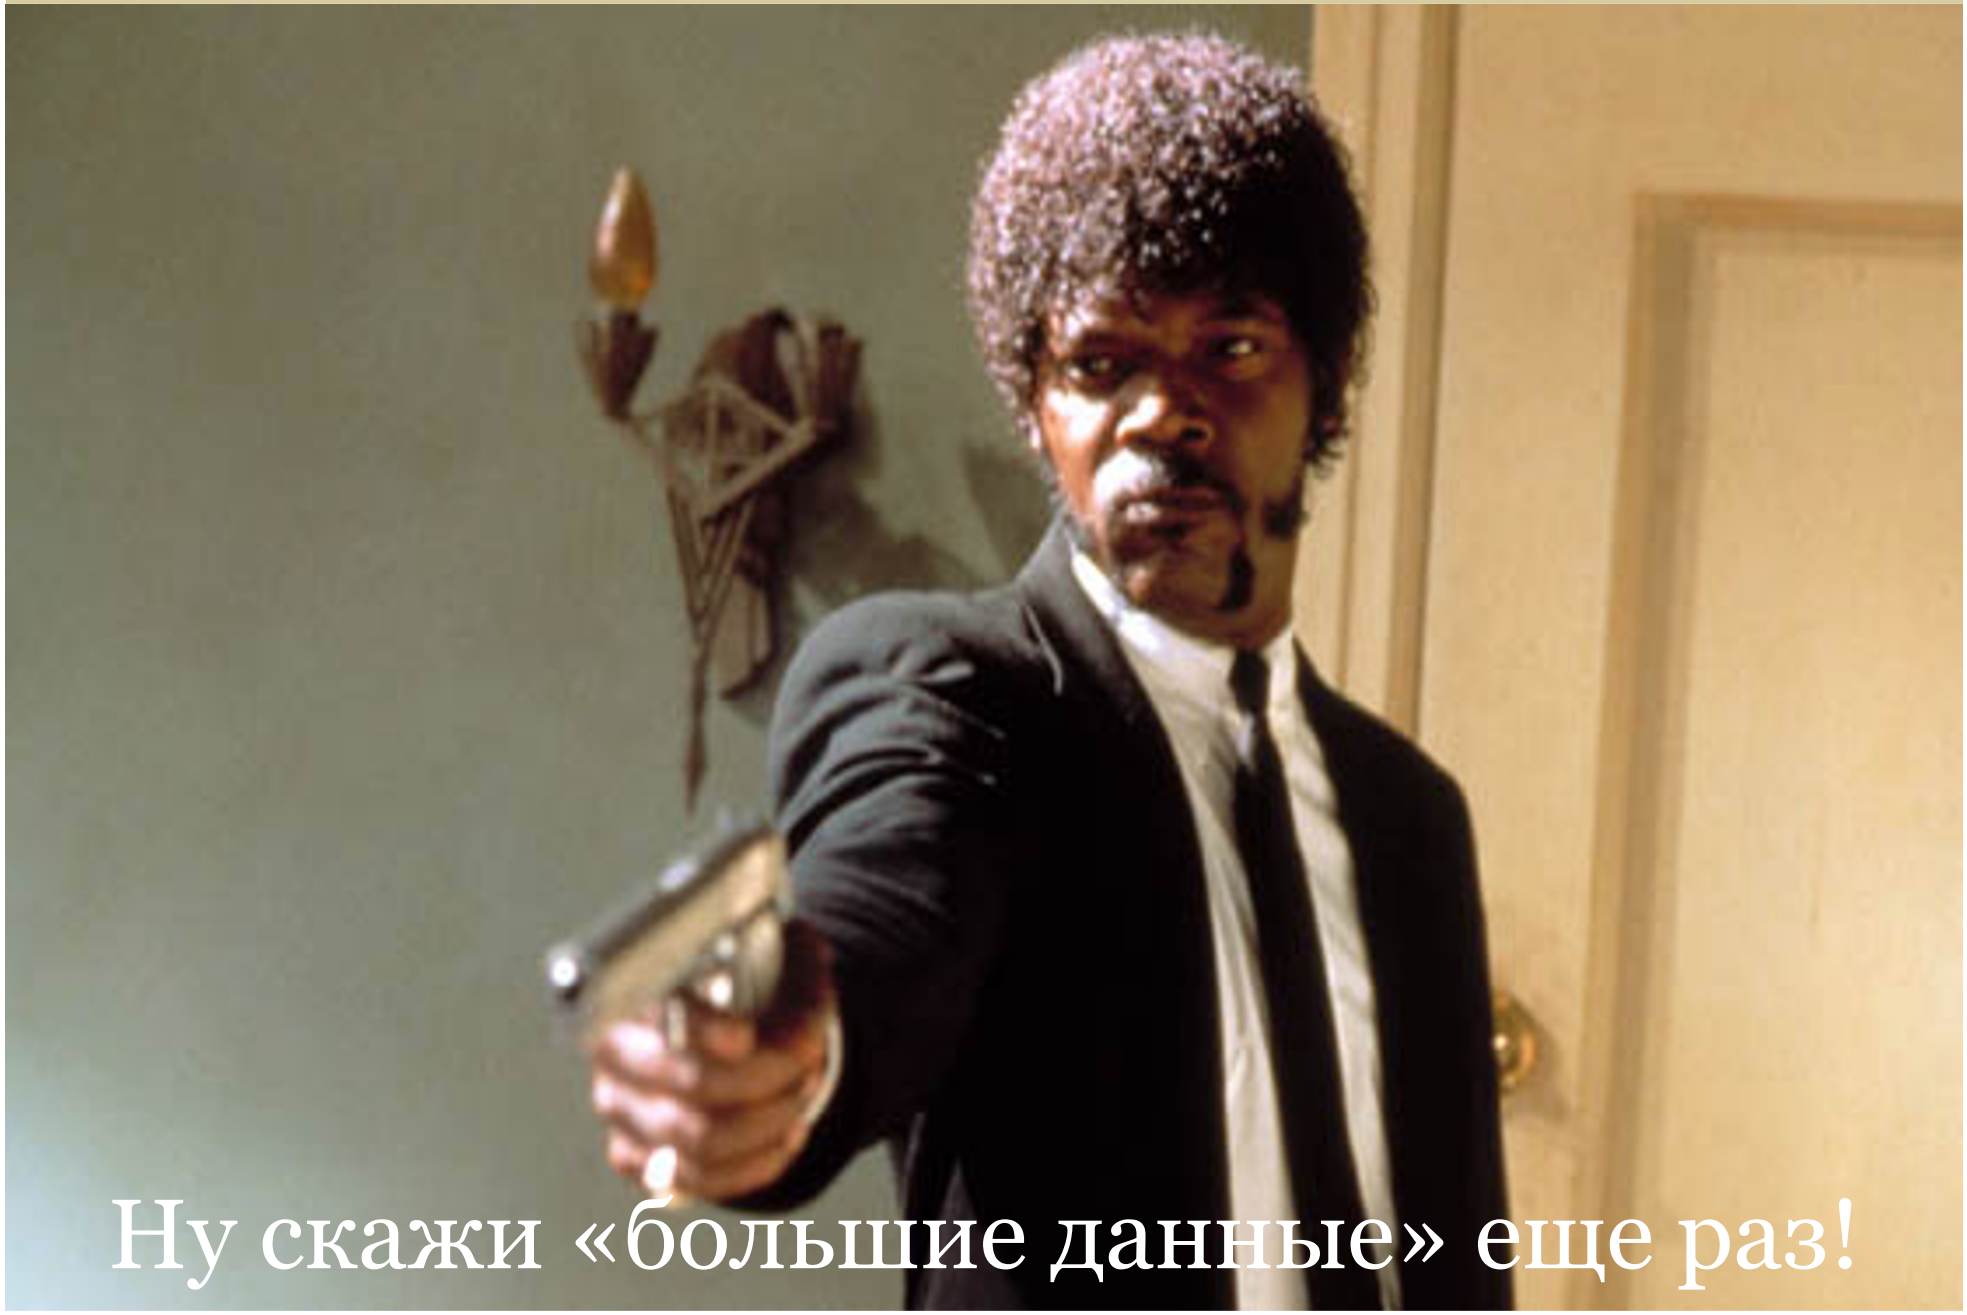

Ну скажи «большие данные» еще раз!

Большие Данные

в системах онлайн обучения

Большие данные в онлайн обучении это…

- Шанс увидеть общую картину (данные не отобраны специально)
- Модели построенные на больших данных более обобщаемые
- Для обобщения доступны не 2-3 группы студентов
  - 10-ки групп, 1000-чи студентов, 10-ки миллионов записей
- Труднее контролировать честность сравнительных экспериментов
  - В сравнительном эксперименте проводимом фирмой RAND[1], часто, более слабые студенты попадали в экспериментальную группу (с когнитивным наставником)
- Сильный перекос во времени работы и покрытии материала
  - Большинство студентов занимаются меньше
- Определенный процент данных точно будет испорчен
  - В данных фирмы Carnegie Learning за 2010 год, только 240 школ из 900 собрали данные (и 25% из оставшихся данных были непригодны)
  - В МООК-ах, по ходу курса, студенты «пропадают»

[1] Pane, J.F., Griffin, B.A., McCaffrey, D.F., & Karam, R. (2014). Effectiveness of Cognitive Tutor Algebra I at scale. Educational Evaluation and Policy Analysis, 36 (2), 127-144.

Моделирование знаний

в системах онлайн обучения

Моделирование знание

- ***Студент*** взаимодействует с ***задачей*** (или ее шагом) и меняет уровень знания ***концептов*** напр., `“цикл for”, “цикл for исполняемый только 1 раз”`
  - Словарь концептов определен заранее
  - Задачи/шаги ***проиндексированы*** концептами
- После каждого действия студента, вероятностный уровень знаний концепта обновляется
- Концепт считается изученным, если вероятностный уровень знаний достигает определенного значения (напр. ≥0.95)

Байесовское отслеживание знаний[2]

- Вариант скрытой Марковской модели
- Массово используется в «когнитивных наставниках»
- Наблюдаемый результат: правильность применения концептов (правильно, неправильно)
- Скрытое состояние: (выучен, не выучен)
- Пять вероятностных параметров (четыре ненулевых)
  - в. что концепт выучен заранее – pInit, $p(L_0)$
  - в. выучивания при каждой возможности применения – pLearn, p(T)
  - в. «забывания» при каждой возможности применения – pForget, p(F) = 0
  - в. ошибки на выученном концепте – pSlip, p(S)
  - в. правильного ответа на невыученном концепте – pGuess, p(G)

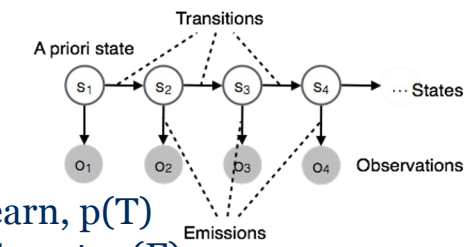

- Для отслеживания одна модель на каждую пару пользователь-концепт
- Построение модели из данных (одна модель на концепт): EM-алгоритм
- Множество точек экстремума целевой функции

[2] Corbett, A. T. & Anderson, J. R. (1995). Knowledge tracing: Modeling the acquisition of procedural knowledge. User Modeling and User-Adapted Interaction, 4(4), 253-278.

Модель аддитивных факторов (АФМ)[2]

[2] Cen, H., Koedinger, K. R., & Junker, B. (2006). Learning Factors Analysis: A general method for cognitive model evaluation and improvement. In: Proceedings of ITS 2006

- Часто используется в аналитике для онлайн курсов обучения (напр. LearnLab's LearnSphere)
- Является логистической регрессией со случайными эффектами
- Два параметра на каждый концепт
  - сложность концепта (β), в. знания концепта заранее
  - скорость выучивания (γ), в. выучивания концепта при каждой возможности
- Один параметр на каждого студента
  - студенческая способность, случайный эффект (θ)
  - Y_{ij} – правильность ответа на вопрос j студентом i
  - t_{ik} – количество предшествующих шансов применить концепт k студентом i

$$Y_{ij} = logit\left(\theta_i + \sum_{k=1}^{skills(j)} (\beta_k + \gamma_k t_{ik})\right)$$

- Построение модели: метод максимального правдоподобия
- Существует единственная точка экстремума

Построение моделей обучения на больших данных

Байесовское отслеживание знаний

Модель аддитивных факторов

Построение моделей на больших данных

- Кубок KDD 2010
  - Данные собранные когнитивным наставником от компании Carnegie Learning
  - 2 массива данных: 9M и 20M элементов
  - 2 место завоевала команда использовавшая БОЗ
  - Для построения модели требовался кластер компьютеров с Matlab
  - **А можно ли быстрее? Победители использовали собственный пакет и модель с 20M параметров**

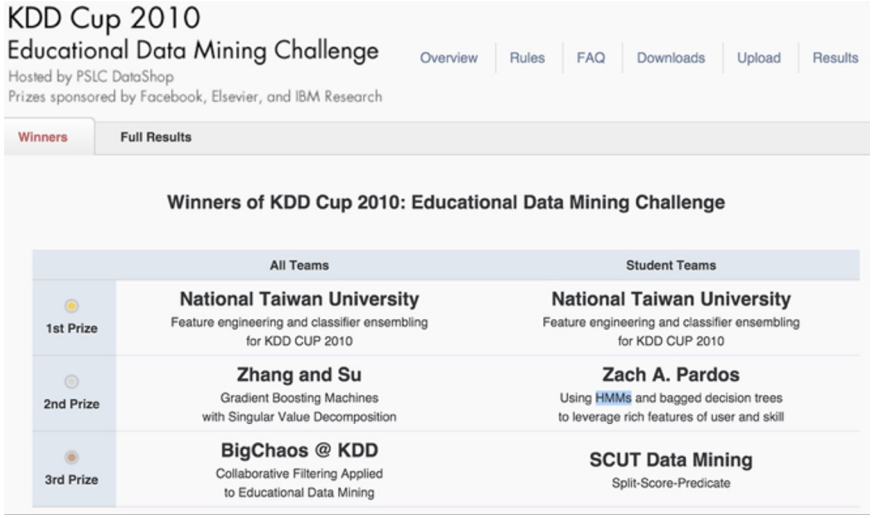

KDD Cup 2010
Educational Data Mining Challenge
Hosted by PSLC DataShop
Prizes sponsored by Facebook, Elsevier, and IBM Research

Overview | Rules | FAQ | Downloads | Upload | Results

Winners | Full Results

Winners of KDD Cup 2010: Educational Data Mining Challenge

	All Teams	Student Teams
1st Prize	**National Taiwan University** Feature engineering and classifier ensembling for KDD CUP 2010	**National Taiwan University** Feature engineering and classifier ensembling for KDD CUP 2010
2nd Prize	**Zhang and Su** Gradient Boosting Machines with Singular Value Decomposition	**Zach A. Pardos** Using HMMs and bagged decision trees to leverage rich features of user and skill
3rd Prize	**BigChaos @ KDD** Collaborative Filtering Applied to Educational Data Mining	**SCUT Data Mining** Split-Score-Predicate

Построение БОЗ моделей на больших данных (1)

- hmm-scalable[3] (open-source проект, утилита командной строки)
  `http://yudelson.info/hmm-scalable`

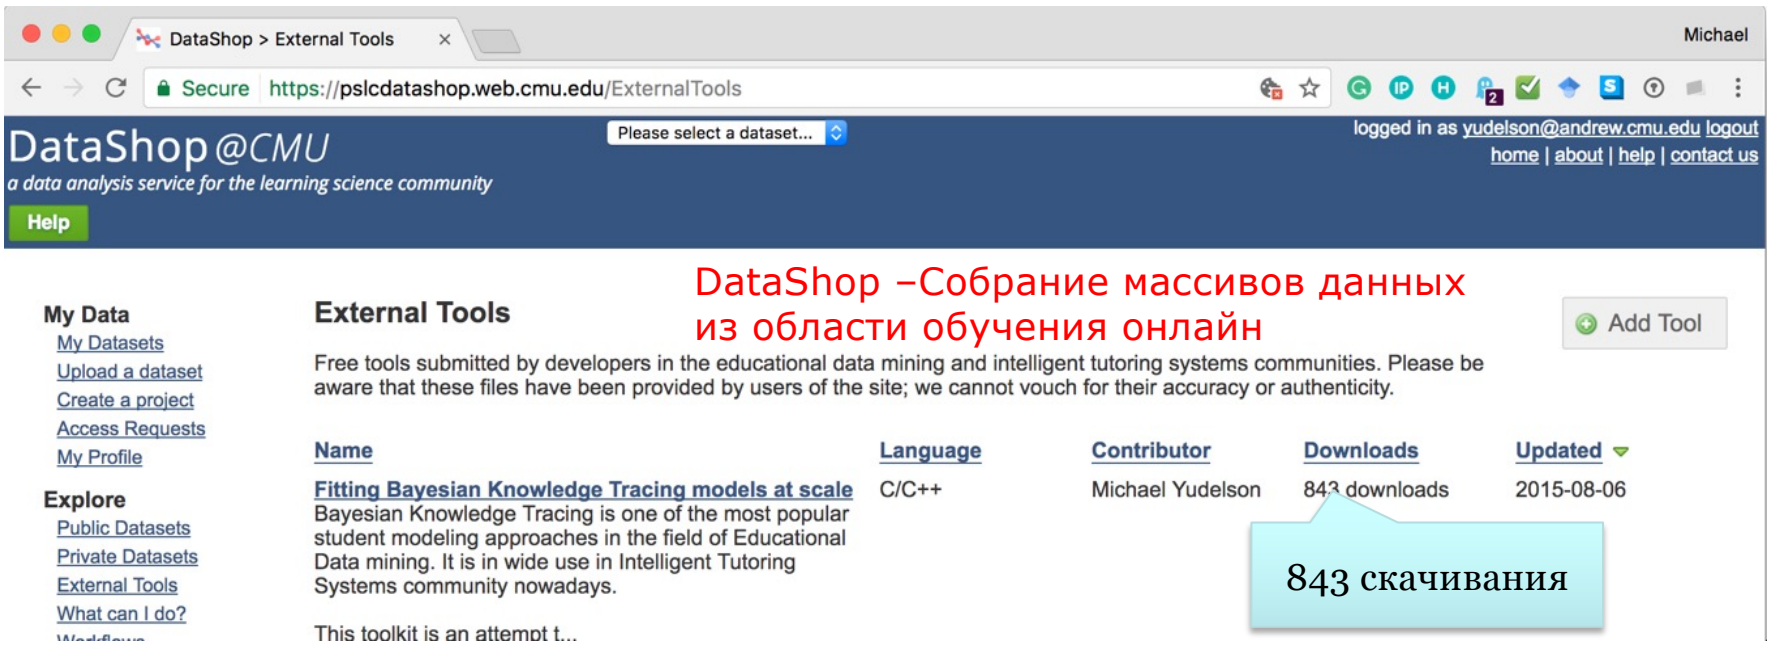

DataShop –Собрание массивов данных из области обучения онлайн

843 скачивания

[3] Yudelson, M., Koedinger, K., Gordon, G. (2013) Individualized Bayesian Knowledge Tracing Models. In: Proceedings of 16th International Conference on Artificial Intelligence in Education (AIED 2013)

Построение БОЗ моделей на больших данных (2)

- Утилита использована для получения результатов опубликованных в нескольких журнальных статьях и в докладах на концеренциях.
- Возможности
  - Формат входных данных 4 колонки
    - Результат (правильно/неправильно), Студент, Элемент материала, Концепты
  - 7 алгоритмов решателей (+2 в разработке)
    - ЕМ-алгоритм, градиентный спуск, градиентный метод Лагранжу, метод сопряжённых градиентов (4)
  - Параметризацией студентов
  - Поддерживает, в том числе:
    - мультипроцессорный режим
    - количество скрытых состояний БОЗ >2
    - перекрестную проверку моделей
    - усадку параметров
    - разреженные данные студент-концепт (библиотека boost)

Построение БОЗ моделей на больших данных (3)

- Построить модель на миллиарде элементов [симулированных] данных
  - Состояний=2, наблюдений=2, концептов=10,000 студентов≈100,000, студент-концепт≤100
  - Размерность=902,685,316, процент верных ответов=**0.50**
  - Файл данных: .txt=20.56Gb, .bin=11.74Gb

3 минуты

```
trained model LL=560734354.6932430 (560734354.6932430),
AIC=1121548709.386486, BIC=1122293544.769021, RMSE=0.465350
(0.465350), Acc=0.660134 (0.660134)

timing: overall 14472.119228 sec, read 183.496959 sec, fit
1164.401084 sec, predict 12791.454573 sec
```

20 минут

3.5 часов

Построение АФМ моделей на больших данных

- LIBLINEAR[4]
  - Пакет для построения логистических регрессивных моделей
  - Создан/использован победителями Кубка KDD 2010 из Национального Универпситета Тайваня
  - Не реализует случайные эффекты
- Модификация LIBLINEAR
  `github.com/IEDMS/liblinear-mixed-models`
  - Дополнительный алгоритм решатель логистической регрессией со случайными эффектами
  - Реализует усадку параметров по группам
  - Позволяет строить модели со вложенными случайными эффектами (HLM модели)

[4] R.-E. Fan; K.-W. Chang; C.-J. Hsieh; X.-R. Wang; C.-J. Lin (2008). "LIBLINEAR: A library for large linear classification". Journal of Machine Learning Research 9: 1871–1874

Модели знаний в МООК-ах

неструктурированные данные
без существующих словарей концептов

Программируют все (или хотят программировать)

- Программирование больше не профессия избранных
  - Широкое распространение информатики
  - Сложность для преподавателей: знания и умения приходящих студентов сильно разнятся
- Многообразия учебных материалов недостаточно
  - Даже цифровые материалы не собирают информации о прогрессе студентов и росте их знаний
  - Инновационные подходы локальны и не масштабируются (хотя имеют такой потенциал)
  - Выходят все новые и новые языки программирования
- Можно ли построить модель знаний пользователя ***автоматически*** чтобы использовать ее для адаптации позже?

Описание ситуации

- Курс программирование на Java (традиционный и МООК) в Хельсинском Университете
  - В курсе ~100 задач на программирования (10^1-10^4 строк кода)
  - Задачи от простых до сложных
  - Плагин для IDE NetBeans
    - Проверка правильности решения задачи локально (малый набор тестов)
    - «Сдача» задачи на сервер проверки (полный набор тестов)
    - Текст программы архивируется при любом его изменении
  - В режиме онлайн идет проверка на синтаксические ошибки
  - [Постоянной] модели студенческих знаний нет

Вопросы и Подход

- Вопросы
  - Можно ли построить ***приемлемые*** модели знаний студентов ***автоматически*** в контексте типового традиционного курса или МООКа?
  - Будет ли такая модель полезна для создания адаптивной надстройки над существующим решением?
- Подход
  - Анализировать последовательности редактирования кода (только те точки, где студенты тестировали или «сдавали» код)
  - В качестве концептов, использовать узлы дерева разбора программы (генерируется автоматически без ручной доводки)

Данные

Курс	Студентов Всего (м.)	Возраст мин/мед/макс	Элементов данных всего/ мед
Программирование на Java, Осень 2012	185 (121)	18 / 22 / 65	204 460 / 1131
Программирование на Java, Осень 2013	207 (147)	18 / 22 / 57	263 574 / 1126
Программирование на Java МООК, Весна 2013	683 (492)	13 / 23 / 75	842 356 / 876
	951 (760)		

Точность модели знаний пользователя

- Точность= $\frac{\text{правильных предсказаний результата тестировани программы}}{\text{всего проверенных программ}}$
- Нуль-модель (всегда предсказывать «неправильно»): точность= 0.56
- Модель Раша (Rasch): точность = 0.71
- БОЗ модель не подходит для этой задачи (x10 концептов на задачу)
- Модифицированная АФМ модель: точность=0.75
  - Концепты локальны для задачи, а не глобальны для всего курса
  - Логарифмирование количества попыток на концепт
    - В тои числе компенсирует разную интенсивность проверки/сдачи у студентов
  - Оставить только самые «влиятельные» концепты (алгоритм PC[5])
  - В будущем: только концепты «участвовавшие» в успешных решениях

[5]Spirtes, P., Glymour, C., and Scheines, R. (2000) Causation, Prediction, and Search, 2nd Ed. MIT Press, Cambridge MA.

Будет ли такая АФМ модель полезна?

- Адаптивная навигация неприменима
  - Последовательность задач фиксирована
- Использование модели знаний пользователя для генерирования подсказок на какой концепт обратить внимание
  - «Проиграть» данные интерактивно и дать модели «проголосовать» за изменения в коде программ
  - А. падение количества пройденных программой тестов должно вести к преобладанию отрицательных «голосов» модели (% случаев)
  - Б. рост количества пройденных программой тестов должно вести к преобладанию положительных «голосов» модели (% случаев)
  - В. неизменно низкое количество пройденных программой тестов не должно получать положительных «голосов» модели (% случаев)
  - Г. неизменно высокое количество пройденных программой тестов не должно получать отрицательных «голосов» модели (% случаев)
- Среднее значение АБВГ = 62%

Промежуточные выводы

- Полностью автоматизировать построение модели знаний пользователя в программировании – возможно
- Построенные модели имеют практическую пользу
- Отношение между точностью, сложностью, и практической пользой альтернативных моделей – неоднозначны
  - Сложность и точность коррелируют напрямую
  - Точность и практическая польз коррелируют обратно

Высокоуровневая адаптация в МООК-ах

на основе автоматически простоенных моделей

Стереотипная адаптация

- Без адаптации
  - Каждый пользователь получает одинаковую систему
- Стереотипная адаптация
  - Пользователи делятся на группы
    - напр. более или менее подготовленные студенты
  - Каждая группа получает разные системы
    - напр. различаются настройки моделей пользователя

Постановка задачи

- Существует ли такое разбиение студентов на группы, что
  - Модели знаний для них отличаются?
  - Модели знаний для одной группы не подходят (менее точны) для другой?
- Примеры разбиений на группы
  - Простые (и понятные): пол, образование, прилежание
  - Сложные (и эффективные): на основе ***поведения*** при решении задач на программирование
- Группы должны быть существенного размера
- Хотя бы две отличающиеся друг от друга
- Тип моделей тот же что и в предыдущем исследовании: вариант АФМ

Критерий проверки гипотезы

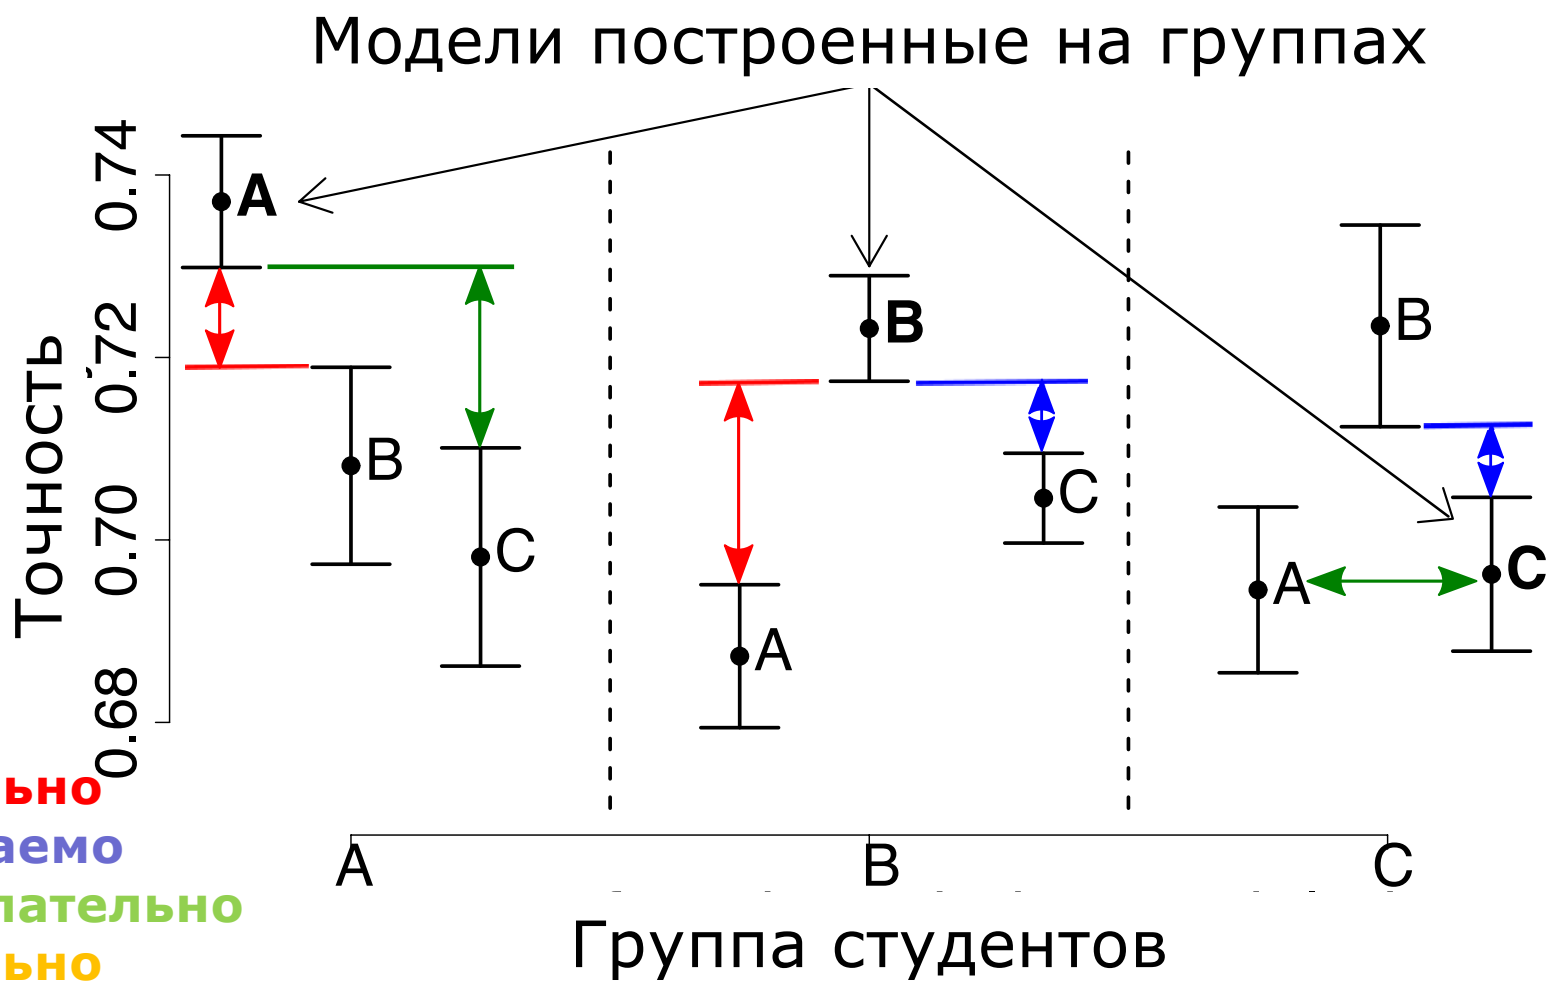

идеально
ожидаемо
нежелательно
печально

Поведение при решении задач

- Два фактора при переходе от предыдущего состояния текста программы к последующему
  - Дерево разбора (и количество концептов) неизменно/увеличилось/уменьшилось (3)
  - Правильность: нулевая/такая же (ненулевая)/уменьшилась/увеличилась (4)
- Дополнительный фактор: временное окно
- На основе частотной матрицы 3x4 сгруппировать студентов
  - напр.: Страдатели, Строители, Урезатели, и Массажеры
  - напр.: Двигатели, «Кулибины»,…

Пример сравнения двух кластеров

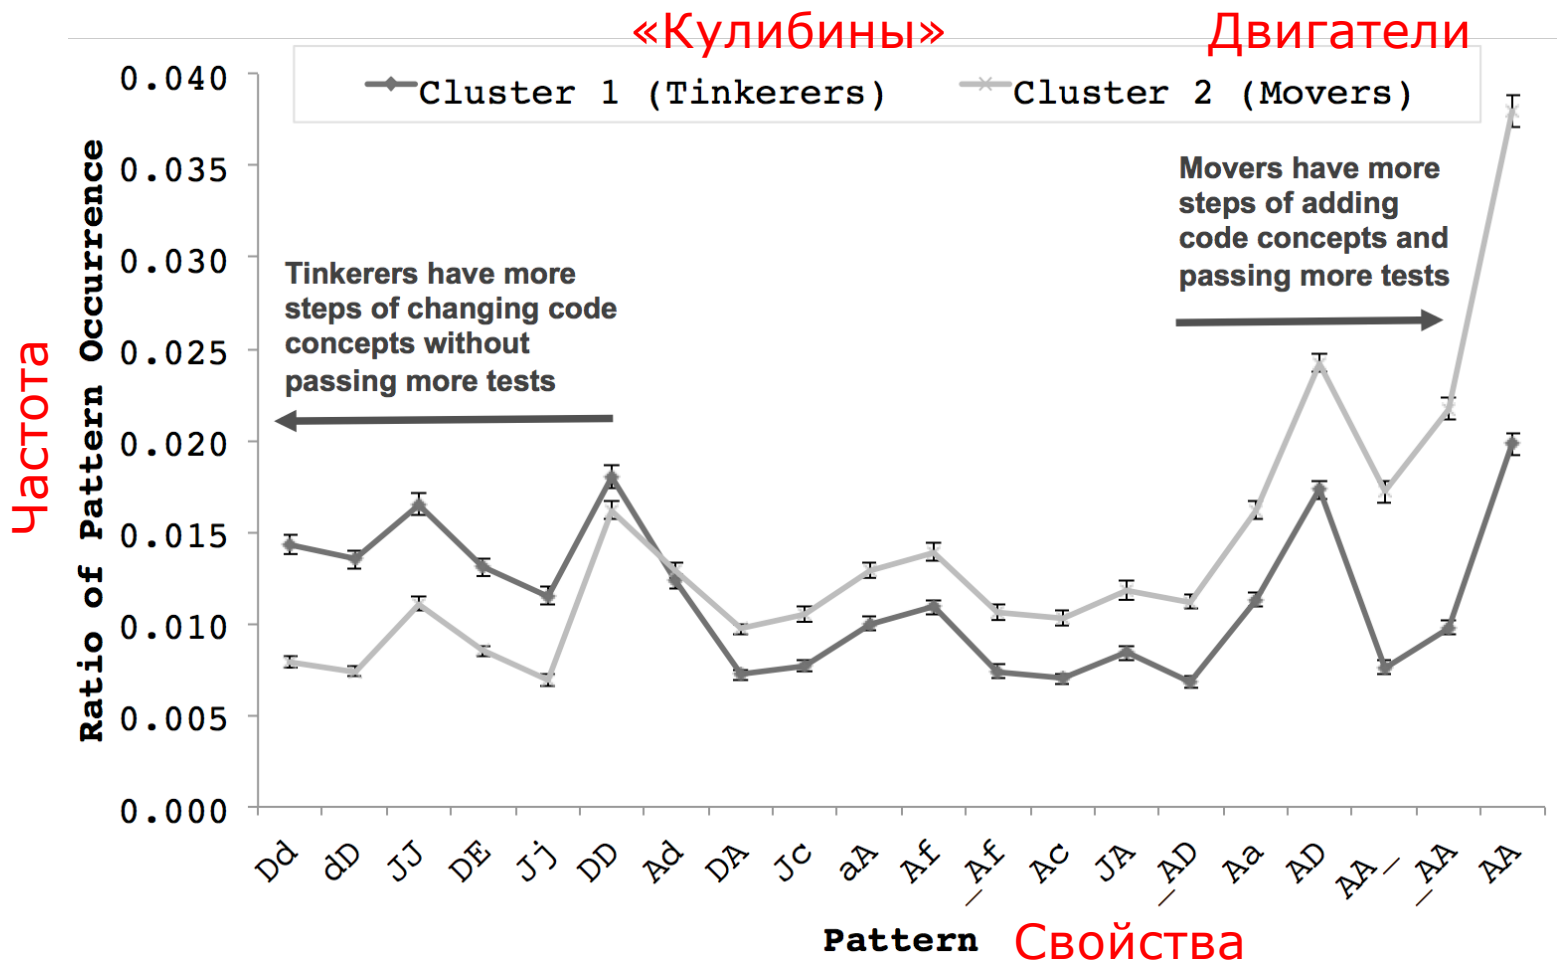

Результаты

Фактор разбиения (число свойств)	Размеры групп	Результат
Пол (1)	570, 228	нежелательно
Образование (1)	524, 154, 120	печально
Кол-во сдач (1)	266, 266, 266	ожидаемо
% решено (4)	218, 316, 264	печально
% правильно (1)	266, 266, 266	печально
Кластеры 1 (45)	383, 415	ожидаемо
Кластеры 2 (245)	416, 382	ожидаемо
Кластеры 3 (245)	258, 158, 382	ожидаемо
Кластеры 4 (245)	295, 503	ожидаемо
Кластеры 5 (245)	389, 272, 137	ожидаемо

При последующем сравнении параметров построенных моделей существенной разницы между моделями групп выявлено не было

Промежуточные выводы

- Похожий результат был получен в другой предметной области (математика) в другой системе (когнитивный тренер) и на других студентах (школьники в США)
- Использование стереотипов (групп) студентов как основы адаптации – проблематично
  - Ни простые разбиения, ни кластеры на основе поведений студентов не дали искомого результата
- Подозрения
  - Стереотипы для адаптации непригодны (спорно)
  - Поведение кодирования следует рассматривать локально, в том моменте, к которому оно прилагается (как план на будущее)

Спасибо за внимание!

Mikhail Yudelson

yudelson@andrew.cmu.edu

Благодарности

- Петр Леонидович Брусиловский (Университет Питтсбурга)
- Кеннет Кёдингер (Университет Карнеги Меллон)
- Джеффри Гордон (Университет Карнеги Меллон)
- Филип Павлик (Университет Мемфиса)
- Стив Риттер (Carnegie Learning, Inc.)
- Стивен Фансали (Carnegie Learning, Inc.)
- Сергей Сосновский (Университет Утрехта)
- Джей-Вук Ан (IBM)
- Роста Фарзан (Университет Питтсбурга)
- Шерон (Ихан) Сяо (Государственный Университет Аризоны)